树模型：壹 · 决策树与随机森林（理论篇）

Pengpeng Zhou

北京工商大学　经济学院
m3126211047@163.com

2026 年 10 月 7 日

目录

1. 基本概念
2. 分类决策树
3. 回归决策树
4. 超参数与剪枝
5. 随机森林
6. 损失函数与金融实践
7. 模型对比与学习路线

我们到底要预测什么？

- 机器学习通常把一行数据分成两部分：
  - **特征**（feature，记作 X）：预测时可以观察到的信息，例如收入、负债率、是否有逾期记录
  - **目标**（target，记作 y）：我们希望模型预测的答案

客户	年收入	负债率	过去是否逾期	最终是否违约
A	12 万	低	否	否
B	8 万	高	是	是

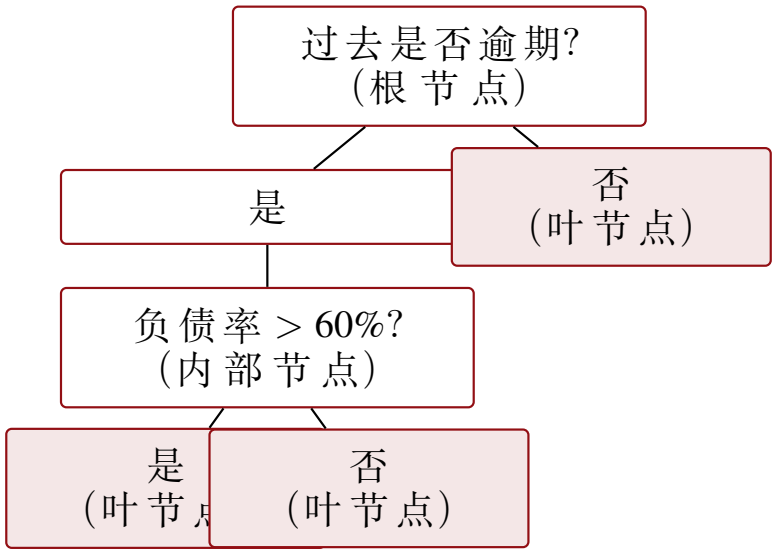
- 前四列是特征，最后一列是目标

分类与回归

- 目标是有限个类别，就是**分类**：
  - 是否违约：是 / 否；
  - 风险等级：低 / 中 / 高；
  - 股票方向：上涨 / 横盘 / 下跌。
- 目标是连续数值，就是**回归**：
  - 下一月损失金额；
  - 房贷违约损失率；
  - 股票下一月收益率；
  - 客户终身价值。
- 分类树可以输出“违约概率 0.8”；回归树可以输出“预计损失 12 万元”，二者不是同一件事

决策树的基本术语

- 根节点（root）：整棵树最上方的第一个判断
- 内部节点（node）：中间的判断，例如负债率 $> 60\%$?
- 分支（branch）：判断结果通往下一节点的路径
- 叶节点（leaf）：不再继续分裂的终点
- 深度（depth）：从根到节点经过的层数



参数与超参数

- **参数**是训练数据学出来的，如“根节点使用负债率，阈值为 60%”
- **超参数**是训练前人为设定的，如 `max_depth=5`、`min_samples_leaf=10`
- 树最终学到的“特征、阈值、左右孩子、叶节点概率/均值”是参数；训练前设置的表格是超参数

一个节点有多“混杂”：Gini 不纯度

- 以二分类“是否违约”为例：某节点有 p_1 的客户违约，有 p_0 的客户不违约

$$Gini(S) = 1 - p_1^2 - p_0^2$$

- 一般的 K 分类形式：

$$Gini(S) = 1 - \sum_{k=1}^{K} p_k^2$$

- 节点全是违约或全是不违约：$Gini = 0$，最纯
- 二分类各占一半：$Gini = 1 - 0.5^2 - 0.5^2 = 0.5$，最混杂

切分后的总 Gini 与增益

- 当前节点有 N 个客户，候选切分得到左右两个子节点，人数分别为 N_L、N_R
- 不能只把两个 Gini 直接相加，要按人数加权：

$$Gini_{split} = \frac{N_L}{N} Gini(L) + \frac{N_R}{N} Gini(R)$$

- 决策树选择 $Gini_{split}$ 最小的切分，等价地最大化不纯度下降：

$$Gain = Gini(parent) - Gini_{split}$$

金融例子：选择根节点

- 8 个客户，目标：是否违约（1 违约，0 不违约）

客户	过去是否逾期	负债率是否高	是否违约
1	是	是	1
2	是	是	1
3	是	否	0
4	否	否	0
5	否	是	0
6	否	否	1
7	是	是	1
8	否	否	0

金融例子：计算加权 Gini

- 候选一：按“过去是否逾期”切分

$$Gini(\text{是}) = 1 - \left(\frac{3}{4}\right)^2 - \left(\frac{1}{4}\right)^2 = 0.375$$

$$Gini(\text{否}) = 1 - \left(\frac{1}{4}\right)^2 - \left(\frac{3}{4}\right)^2 = 0.375$$

$$Gini_{\text{逾期}} = \frac{4}{8}(0.375) + \frac{4}{8}(0.375) = 0.375$$

- 候选二：按“负债率是否高”切分，同样得到 0.375
- 实际数据中若“逾期”得 0.375、负债率得 0.4375，就选“逾期”作根
- 核心：对**每个候选特征和每个候选阈值**计算加权 Gini，取最小者

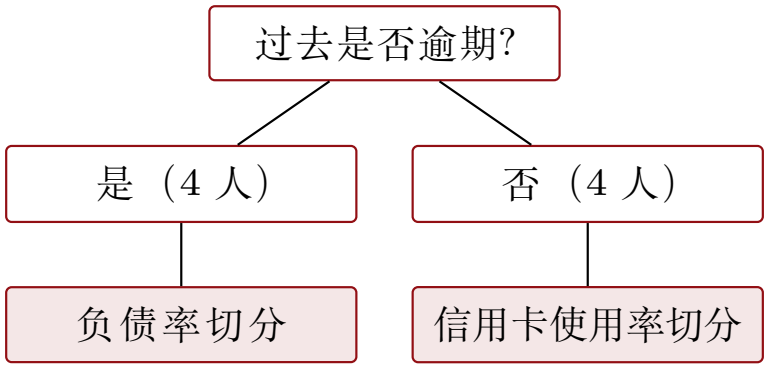
中间节点如何决定？

- 根节点切分后，左右两条路径是两个独立的当前节点
- 每个节点只用到达自己的客户，重新比较候选切分；这不是全局特征排序
- 例：“逾期 = 是”分支有 4 人，再按负债率切分
  - 高负债：2 人，2 人都违约，$Gini = 0$
  - 低负债：2 人，1 人违约、1 人不违约，$Gini = 0.5$

$$Gini_{split} = \frac{2}{4}(0) + \frac{2}{4}(0.5) = 0.25$$

- 把 0.25 与其他候选特征的总 Gini 比较；左边可能选负债率，右边可能选信用卡使用率

中间节点如何决定？（示意图）



- 每到一个节点都重新计算；同一个数值特征还可以在不同节点使用不同阈值

年龄、收入等数值特征的阈值

- 若当前节点中的收入是 4、6、10、15 万，常见候选阈值是相邻值的中点：

$$5, \quad 8, \quad 12.5$$

- 树将分别尝试：

$$\text{收入} \le 5\,? \qquad \text{收入} \le 8\,? \qquad \text{收入} \le 12.5\,?$$

- 选当前节点加权 Gini 最小的阈值
- 若后续只剩收入为 6、10、15 万的客户，要在该子集上重新测试 8、12.5，不能沿用根节点阶段的最佳阈值

多类别分类

- 分类树不限于两类。风险等级为低、中、高，某节点比例为：

$$p_{\text{低}} = 0.5, \quad p_{\text{中}} = 0.3, \quad p_{\text{高}} = 0.2$$

$$Gini = 1 - 0.5^2 - 0.3^2 - 0.2^2 = 0.62$$

- 叶节点中三类数量为低 5、中 3、高 2 时，预测概率为：

$$P(\text{低}) = 0.5, \quad P(\text{中}) = 0.3, \quad P(\text{高}) = 0.2$$

- 最终类别通常取概率最大的“低风险”

分类决策树如何预测

- 训练完成后，输入新客户时**不再计算 Gini，也不再重新选择节点**，只沿已经固定的判断路径走到一个叶节点：

$$\text{新客户：逾期} = \text{是} \rightarrow \text{负债率} > 60\% \rightarrow \text{到达叶节点}$$

- 训练集中到达该叶节点的客户：违约 6 人，不违约 2 人

$$P(\text{违约}) = \frac{6}{8} = 0.75, \qquad P(\text{不违约}) = \frac{2}{8} = 0.25$$

- 分类结果是违约，因为 0.75 大于 0.25
- **概率**是叶节点内的类别比例；**Gini** 用这些比例衡量混杂程度，负责训练时选切分

回归的目标：预测连续数值

- 如果目标是客户下一月的损失金额、房产成交价或股票收益率，使用回归树
- 节点的常见指标是均方误差（MSE）：

$$MSE(S) = \frac{1}{|S|} \sum_{i \in S} (y_i - \bar{y}_S)^2$$

- S：当前节点的样本集合；
- $|S|$：当前节点的样本数；
- y_i：第 i 个样本的真实目标值；
- $\bar{y}_S$：当前节点目标值的平均值

为什么叶节点取平均值

- 同一叶节点里三笔贷款的实际损失金额是 8、10、12 万，叶节点必须用一个数 c 代表它们：

$$L(c) = (8-c)^2 + (10-c)^2 + (12-c)^2$$

- 令它对 c 的导数为零：

$$\frac{dL}{dc} = -2(8-c) - 2(10-c) - 2(12-c) = 0 \qquad \Longrightarrow \qquad c = \frac{8+10+12}{3} = 10$$

- 平方误差下让所有样本共享一个预测值时，最优值就是平均数

$$MSE = \frac{(8-10)^2 + (10-10)^2 + (12-10)^2}{3} = \frac{4+0+4}{3} \approx 2.667$$

回归树的切分与预测

- 候选切分把当前节点分成 3 个样本和 2 个样本：

$$MSE_{split} = \frac{3}{5}MSE(L) + \frac{2}{5}MSE(R)$$

- 树选择加权 MSE 最小的特征和阈值，作用与分类树选择加权 Gini 类似：

	分类树	回归树
衡量指标	Gini / 熵衡量类别混杂	MSE / MAE 衡量数值离散
叶节点输出	类别比例	数值
切分准则	加权 Gini 越小越好	加权 MSE 越小越好

- 新客户沿路径进入叶节点：训练样本损失为 8、10、12 万，树预测 10 万
- 均值易受异常值影响：录入错误应清洗；真实现象可考虑 MAE / 中位数，并用验证集选择方案

决策树的重要超参数

超参数	作用与典型影响
`criterion`	指定节点如何评价切分（Gini、熵、MSE 等）
`max_depth`	最大深度；太大易过拟合，太小易欠拟合
`min_samples_split`	节点至少多少样本才允许分裂；过大可能欠拟合
`min_samples_leaf`	叶节点最少样本数；增大通常更稳健，但可能丢失细节
`max_leaf_nodes`	叶节点总数上限，直接限制模型规模
`max_features`	每次切分最多考虑的特征数，控制随机性与速度
`min_impurity_decrease`	不纯度至少下降多少才分裂，防止无效小切分
`class_weight`	分类类别权重，处理违约少、欺诈少等不平衡问题
`ccp_alpha`	成本复杂度剪枝强度，越大通常剪得越多
`random_state`	固定随机结果，便于复现

- 树学到的“特征、阈值、左右孩子、叶节点概率/均值”是参数；上表是训练前设置的超参数

预剪枝：通过超参数提前停止

- 预剪枝是在生长过程中提前停止：

```
DecisionTreeClassifier(
    max_depth=5,
    min_samples_split=20,
    min_samples_leaf=10,
    min_impurity_decrease=0.001
)
```

- 常见规则：
  - 达到 `max_depth`，停止
  - 当前节点样本少于 `min_samples_split`，停止
  - 分裂后叶节点样本少于 `min_samples_leaf`，停止
  - Gini/MSE 改善小于 `min_impurity_decrease`，停止
- 优点是快、直接；缺点是可能过早停止，导致欠拟合

后剪枝：最小化“误差+复杂度惩罚”

- 先让树长大，再删除收益很小的分支。成本复杂度剪枝常写成：

$$R_\alpha(T) = R(T) + \alpha|L(T)|$$

- $R(T)$：树的误差或节点风险；$|L(T)|$：叶节点数量；α：每增加一个叶节点的复杂度惩罚
- 例如，一个分支让训练误差减少 0.01，但多出 5 个叶子，若 $\alpha = 0.003$，新增复杂度成本就是 $5 \times 0.003 = 0.015$，超过误差改善，剪掉更划算

$$\underbrace{R(T_{\text{旧}}) - R(T_{\text{新}})}_{\text{误差减少量}} > \underbrace{\alpha\big(|L(T_{\text{新}})| - |L(T_{\text{旧}})|\big)}_{\text{新增复杂度成本}}$$

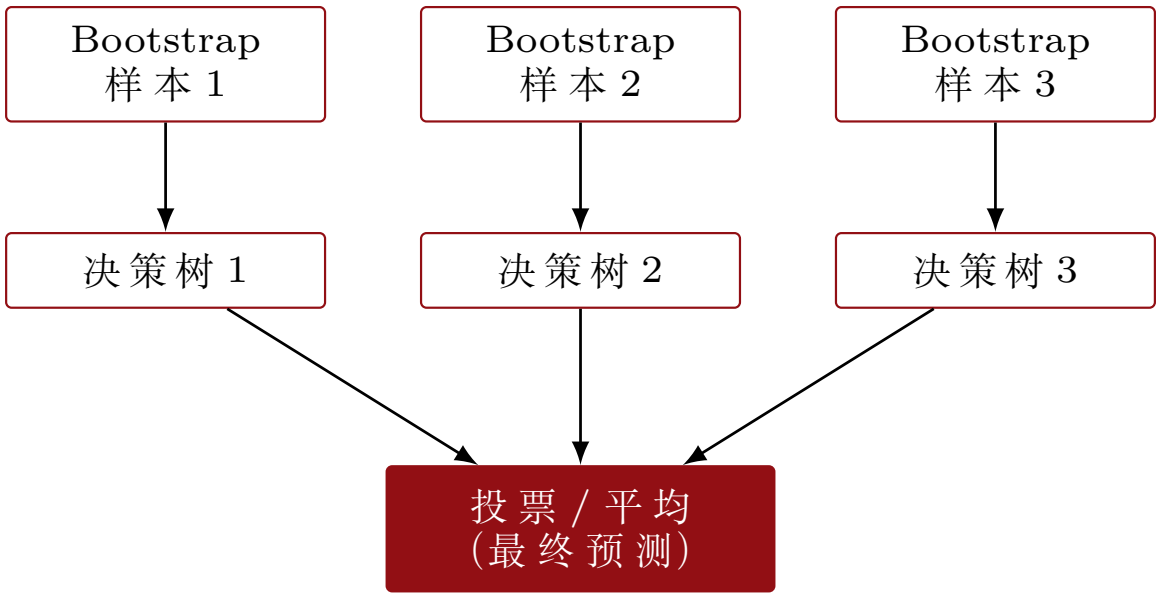
- 长树关注分裂能否改善拟合；后剪枝还要判断这点改善是否值得增加复杂度

过拟合的表现

- 训练很好，新数据明显变差：
  - 训练准确率很高，例如 99%，验证准确率只有 78%
  - 随着树继续变深，训练准确率持续提高，验证准确率却开始下降
- 原因是树把训练数据里的偶然关系、噪声也学了进去，换一批数据就不适用了
- 随机森林与单棵树：过拟合的定义相同，容易程度不同
  - 森林里的每棵树仍是决策树，可以使用上述预剪枝和后剪枝方法
  - 森林通过不同的样本抽样、随机选择候选特征，让多棵树产生不同预测，再汇总结果，减少单棵树的波动
  - 单棵树很深时容易过拟合；随机森林即使每棵树很深，整体仍可能有较好的泛化表现

随机森林：许多棵有差异的决策树

- 随机森林不是先训练一棵“超级大树”，而是训练很多棵彼此不同的树，然后汇总



- 两种随机性：Bootstrap 样本抽样 + 每个节点随机抽特征

随机性一：Bootstrap 有放回抽样

- 原始训练集有 8 个客户：

  1、2、3、4、5、6、7、8

- 训练某棵树时抽 8 次，每次抽完放回，可能得到：

  1、1、1、4、5、6、7、8　　2、3、3、4、5、6、6、8

- 不是简单打乱顺序，而是**有放回抽样**：样本可能重复，也可能没有被抽到
- 没有被抽到的样本叫该树的 OOB（out-of-bag，袋外）样本，可用于内部评估

随机性二：每个节点抽部分特征

- 假设有 5 个特征，设置超参数 `max_features=3`：

根节点抽到：	特征 1、特征 3、特征 5
左子节点重新抽：	特征 2、特征 3、特征 4
右子节点重新抽：	特征 1、特征 2、特征 5

- 每个节点抽到的具体特征可以不同，数量通常由 `max_features` 固定
- 当前节点只在抽到的特征中比较 Gini/MSE，最终只选择其中一个特征真正分裂
- 不同树的根节点不一定相同；同一棵树的不同节点也不必看到同一组特征

随机森林分类：硬投票

- 硬投票只看每棵树的最终类别：

  树 1：违约　树 2：违约　树 3：不违约　树 4：违约　树 5：不违约

- 违约 3 票，不违约 2 票，硬投票结果是违约。数学形式：

$$\hat{y} = \arg\max_{c} \sum_{b=1}^{B} \mathbf{1}\left(h_b(x) = c\right)$$

随机森林分类：软投票

- 软投票保留每棵树的概率：

树	P(违约)	P(不违约)
1	0.80	0.20
2	0.60	0.40
3	0.40	0.60
4	1.00	0.00
5	0.70	0.30

$$P_{\text{forest}}(\text{违约}) = \frac{0.80 + 0.60 + 0.40 + 1.00 + 0.70}{5} = 0.70$$

- 最终选概率最大的类别；硬投票与软投票在某些数据上可能产生不同结果

多类别随机森林

- 三分类“低风险 / 中风险 / 高风险”完全可以直接做。三棵树输出：

树	概率向量
1	$[0.7,\ 0.2,\ 0.1]$
2	$[0.5,\ 0.3,\ 0.2]$
3	$[0.6,\ 0.1,\ 0.3]$

- 逐类别平均：

$$P = \left[\frac{0.7+0.5+0.6}{3},\ \frac{0.2+0.3+0.1}{3},\ \frac{0.1+0.2+0.3}{3}\right] = [0.60,\ 0.20,\ 0.20]$$

- 因此预测为低风险

随机森林回归

- 每棵回归树输出一个数值。5 棵树预测某笔贷款的损失金额：

$$12\ 万、10\ 万、15\ 万、11\ 万、12\ 万$$

$$\hat{y}_{\text{forest}} = \frac{12+10+15+11+12}{5} = 12\ 万元$$

- 这里是两层平均：
  - 每棵树内部，叶节点目标值取平均，得到该树的预测
  - 森林再平均所有树的预测

随机森林的主要超参数

超参数	作用
n_estimators	树的数量，越多通常越稳定，但训练更慢
max_features	每个节点随机考虑的特征数
bootstrap	是否有放回抽样
max_samples	每棵树抽多少样本
max_depth	每棵基础树的最大深度
min_samples_split	节点继续分裂的最少样本
min_samples_leaf	叶节点最少样本
criterion	每棵树的 Gini、熵、MSE 等
class_weight	分类不平衡时调整类别代价
oob_score	是否用袋外样本估计泛化表现
ccp_alpha	对基础树做成本复杂度剪枝
n_jobs	并行使用的 CPU 线程数
random_state	固定随机种子

随机森林为什么通常更稳定

- 单棵树方差高：训练样本稍微改变，根节点和后续分支可能大幅改变
- 森林让很多棵相关性较低的树分别判断，再平均或投票，使极端误差部分抵消
- 它主要降低**方差（variance）**
- 但并不保证消除数据泄漏、标签错误或极端异常值
- 树的数量增加通常让预测更稳定，不意味着森林一定越来越过拟合

成本函数、损失函数与评价指标

- **节点不纯度指标**：训练树时选择切分，如 Gini、熵、MSE
- **损失函数（loss）**：衡量预测与真实答案的差距，如 log loss、平方误差
- **评价指标（metric）**：在验证集或测试集报告效果，如准确率、AUC、RMSE

常用损失函数

- 分类树常用 Gini，熵为：

$$Entropy = -\sum_{k} p_k \log p_k$$

- 概率模型常用对数损失（log loss）：

$$LogLoss = -\frac{1}{n}\sum_{i=1}^{n}\left[y_i \log p_i + (1-y_i)\log(1-p_i)\right]$$

- 回归常用：

$$MSE = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2 \qquad MAE = \frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i|$$

金融风控不能只看准确率

- 违约样本很少时，模型把所有人都判为“不违约”也可能准确率很高，却完全没有风控价值
- 应结合召回率、精确率、F1、ROC-AUC、PR-AUC、Log Loss、校准曲线和业务成本
- 如果漏掉一个真实违约客户的损失远高于误拒一个好客户，可以使用类别权重或自定义阈值，让假阴性成本更高

时间泄漏与类别不平衡

- 时间泄漏：预测 2024 年是否违约时，不能把 2025 年才发生的逾期、催收结果放进特征；金融数据通常应使用时间切分，而不只是随机打乱交叉验证
- 类别不平衡：违约率可能只有 2%，除准确率外要查看：
  - 违约召回率：真实违约抓到了多少
  - 精确率：判为违约的人中有多少真的违约
  - PR-AUC
  - 不同阈值下的业务成本

概率校准与特征重要性

- 概率校准：随机森林的 0.8 不一定代表“长期恰好 80% 的客户违约”；若概率用于定价、准备金或授信额度，要检查校准，可使用 Platt scaling 或 isotonic regression，并在独立验证集上评估
- 特征重要性不是因果关系：树模型的 feature importance 表示预测贡献或分裂使用情况，不等于“这个因素导致违约”；要做因果结论，需要实验设计、工具变量或其他因果方法

决策树、随机森林与提升树的区别

对比	决策树	随机森林	提升树（GBDT/XGBoost）
树的数量	1 棵	多棵	多棵
树之间关系	无	相互独立	后树修正前树
主要机制	递归切分	Bootstrap + 随机特征	梯度/残差逐步修正
分类合并	叶节点类别/概率	投票或概率平均	累加分数再转概率
回归合并	叶节点均值	各树预测平均	初始值 + 修正量
主要降低	建立非线性规则	方差	偏差并逐步提高精度
是否易并行	一棵树内部有限	很容易并行	训练轮次有顺序依赖
解释性	最强	较弱	较弱

提升树的核心思想（预告）

- 提升树的核心公式：

$$F_m(x) = F_{m-1}(x) + \eta\, f_m(x)$$

- 平方损失回归时，下一棵树学习残差：

$$r_i = y_i - F_{m-1}(x_i)$$

- XGBoost 把预测损失和树复杂度放在一个目标中：

$$Obj = \sum_i L(y_i, \hat{y}_i) + \sum_t \Omega(f_t)$$

- 提升树不是随机森林的“简单加大版”：随机森林独立训练后平均，提升树按顺序训练并累加修正

从零学习时的完整流程

1. 明确目标 y 是类别还是连续数值
2. 只用预测时可以获得的特征构造 X
3. 划分训练集、验证集和测试集（金融任务注意时间）
4. 训练一棵小决策树，手算一个节点的 Gini 或 MSE
5. 理解叶节点如何输出概率或均值
6. 调整 `max_depth`、`min_samples_leaf` 等预剪枝参数
7. 训练随机森林，理解样本抽样和节点特征抽样
8. 比较硬投票、软投票和回归平均
9. 用业务相关指标评价，而不是只看准确率
10. 检查泄漏、异常值、概率校准和稳定性

最后记忆三句话

- **决策树**：在当前节点试切分，分类选加权 Gini/熵最小，回归选加权 MSE 最小
- **随机森林**：每棵树用不同的有放回样本，每个节点看随机的一部分特征，最后投票或平均
- **提升树**：后面的树不独立预测，而是按顺序修正前面模型的错误